LAPORAN TUGAS EKSPLORASI MANDIRI

Apache Spark dan NoSQL — Mahadata / Big Data (IF25-40402)

Replikasi Parsial Peramalan Beban Listrik dengan Apache Spark pada Data Low Carbon London

(Ali et al., 2024)



Dzaky Pramadhani 123140208

FAKULTAS TEKNOLOGI INDUSTRI

PROGRAM STUDI TEKNIK INFORMATIKA

INSTITUT TEKNOLOGI SUMATERA

2026

A. Ringkasan Jurnal

Sitasi. Ali, H. A. E.-S., Alham, M. H., & Ibrahim, D. K. (2024). Big data resolving using Apache Spark for load forecasting and demand response in smart grid: A case study of Low Carbon London Project. *Journal of Big Data, 11*, Article 59. `https://doi.org/10.1186/s40537-024-00909-6`

Reputasi. Artikel terbit di *Journal of Big Data* (Springer Nature), memiliki DOI, dan terbit pada 28 April 2024 (memenuhi syarat 2019 ke atas). Kuartil SJR: Q1 pada tahun 2024 di keempat kategorinya (*Computer Networks and Communications*, *Hardware and Architecture*, *Information Systems*, dan *Information Systems and Management*) menurut scimagojr.com. Tanggal diterima dan disetujui: 07 April 2024.

Masalah. Data meter pintar pada jaringan listrik pintar (*smart grid*) berukuran sangat besar sehingga peramalan beban (*load forecasting*) dan respons permintaan (*demand response*) membutuhkan pengolahan terdistribusi. Artikel menunjukkan bahwa Apache Spark dapat dipakai untuk membersihkan, menganalisis, dan memodelkan data tersebut.

Dataset dan lingkungan artikel. Proyek Low Carbon London: 5.567 rumah tangga dengan lebih dari 167 juta rekaman, ditambah data cuaca dan hari libur. Lingkungan berupa Google Cloud Dataproc dengan 1 *master* dan 3 *worker* (masing-masing 2 vCPU dan 7,5 GB RAM) serta HDFS, dengan Spark SQL dan MLlib (PySpark).

Metode. Dua keluarga model dibandingkan untuk memprediksi total beban: regresi polinomial berganda (MPR) dalam empat varian (Plain, Ridge, Lasso, *Elastic Net*) dan *decision tree regressor* (DTR) dengan kedalaman maksimum 5. Model per blok memakai empat fitur: jumlah rumah (`count(LCLid)`), *apparent temperature*, jam, dan penanda akhir pekan/libur. Metrik evaluasi adalah R^2, MAE, MSE, dan RMSE, ditambah waktu *fit* dan waktu uji.

Hasil utama. Untuk satu blok (Block 0), artikel melaporkan R^2 0,944 (Plain) dan 0,943 (Ridge, Lasso, *Elastic Net*) untuk MPR, serta 0,910 untuk DTR; RMSE MPR 2,472–2,501 dan DTR 3,215 (Tabel 6 artikel, hlm. 19). Artikel menyimpulkan bahwa regularisasi tidak mengubah akurasi secara berarti, MPR lebih akurat daripada DTR, dan waktu *fit* Lasso dan *Elastic Net* lebih tinggi daripada Ridge.

Alasan memilih. Artikel memuat metode yang dapat dijalankan, datanya terbuka, perangkat lunaknya sumber terbuka, metrik dan model dilaporkan cukup jelas, serta bagian per blok (sekitar 50 rumah) dapat dijalankan pada Spark mode lokal tanpa klaster.

B. Tahapan Implementasi dan Eksperimen

B.1 Tingkat replikasi

Replikasi **parsial**: lima model (Plain, Ridge, Lasso, *Elastic Net*, DTR) direplikasi pada satu blok data (Block 0, 50 rumah) dengan Spark mode lokal, bukan klaster Dataproc. Kolom *all houses* pada artikel tidak direplikasi.

B.2 Rancangan eksperimen

Unsur	Isi
Tujuan	Menguji apakah pola kinerja lima model pada artikel (MPR lebih akurat daripada DTR, regularisasi tidak mengubah akurasi) terulang pada Block 0 dengan Spark mode lokal.
Data	*Smart meters in London* (Kaggle), Block 0: 50 rumah, 2011-12-03 s.d. 2014-02-28, ditambah cuaca per jam dan *UK bank holidays*.
Lingkungan	Spark mode lokal di Google Colab.
Langkah	Pembacaan dan pembersihan, agregasi dan *join*, analitik deskriptif (Spark SQL), seleksi fitur, pemodelan MPR dan DTR, evaluasi, perbandingan dengan artikel.
Keluaran dibandingkan	R^2, MAE, MSE, RMSE (Tabel 6 artikel), korelasi antarfitur (Gambar 3–4 artikel), serta urutan waktu *fit*/uji.

B.3 Lingkungan dan versi perangkat lunak

Komponen	Versi
Platform	Google Colab
OS	Linux 6.6.122+ (x86_64, glibc 2.39)
Python	3.13.15
Java	OpenJDK 21.0.12.1
Apache Spark / PySpark	4.0.4
pandas	2.2.3
Mode eksekusi	`local[*]`, *driver memory* 6 GB
Random seed	42

B.4 Langkah demi langkah

- **Pembacaan data.** Data dibaca sebagai teks dengan skema eksplisit karena kolom energi memuat string `"Null"` sehingga `inferSchema` salah menebak tipe. Konfigurasi `spark.sql.ansi.enabled=false` dipakai agar *cast* `"Null"` menghasilkan `null` dan tidak galat, dan zona waktu sesi ditetapkan UTC. Berkas yang terbaca adalah `daily_dataset/block_0.csv` (lihat B.5 dan Catatan sumber data).
- **Pembersihan.** Mengikuti artikel, nilai *null* dan nol dibuang; nilai negatif juga dibuang. Dari 25.574 baris mentah, tidak ada baris yang dibuang.
- **Agregasi dan *join*.** Energi dijumlahkan per *timestamp* lintas rumah menjadi `energy_sum`, dengan `n_house` sebagai jumlah rumah tercatat. Cuaca (`apparentTemperature`, rata-rata per jam) digabung dengan *left join*, hari libur digabung per tanggal, lalu dibentuk fitur `hour` dan `weekend` (Sabtu, Minggu, atau hari libur). Hasilnya 819 *timestamp*; satu dibuang karena tidak ada data cuaca, sehingga tersisa 818.
- **Validasi.** Notebook memeriksa bahwa lima kolom akhir tidak memuat *null*, lalu menyimpan hasil sebagai Parquet.
- **Analitik dan seleksi fitur.** Kueri deskriptif memakai Spark SQL pada *temp view*. Seleksi fitur memakai korelasi Pearson (`pyspark.ml.stat.Correlation`) dengan ambang kolinearitas $|r| \geq 0{,}8$; cuaca dibaca ulang lengkap hanya untuk analisis korelasi.
- **Pemodelan.** Data dibagi acak 80/20 dengan *seed* 42 (662 latih, 156 uji). MPR memakai `VectorAssembler`, `PolynomialExpansion` derajat 2, dan `LinearRegression` (Plain tanpa regularisasi; Ridge, Lasso, *Elastic Net* dengan `elasticNetParam` 0, 1, dan 0,5). Nilai λ dipilih dari $\{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}\}$ dengan

`CrossValidator` 3-*fold* (metrik R^2). DTR memakai `maxDepth`=5 tanpa *tuning*.

- **Evaluasi.** R^2, MAE, MSE, dan RMSE pada data uji memakai `RegressionEvaluator`.
- **Waktu.** Waktu *fit* mencakup seluruh `.fit()` termasuk validasi silang; waktu uji diukur pada `transform` dengan penulisan *noop* agar komputasi berjalan penuh. Pengukuran dilakukan satu kali.

B.5 Perbedaan terhadap artikel

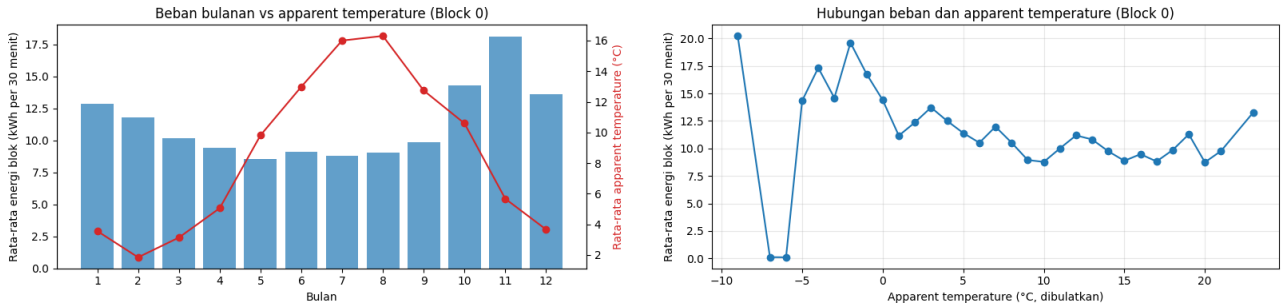
Aspek	Artikel	Replikasi ini	Alasan
Data	5.567 rumah, >167 juta rekaman; per blok memakai Block 0 (setengah-jam)	Block 0 saja, **data harian** (818 hari)	Berkas yang terbaca ternyata `daily_dataset`; disadari setelah hasil ditinjau
Klaster	Dataproc 1 *master* + 3 *worker*, HDFS	Spark `local[*]`, satu mesin	Gratis dan ringan
Cuaca dan libur	Dark Sky API dan *bank holidays*	Salinan turunan Kaggle	Sumber asli tidak dipakai
Pembersihan	Buang null dan nol; diagram juga memuat eksklusi *outlier*	Buang null, nol, negatif; tanpa eksklusi *outlier*	Aturan *outlier* tidak dirinci
Praproses MPR	*One-hot*, polinomial, *standard scaling*, eliminasi fitur	Polinomial dan standardisasi internal; tanpa *one-hot* dan eliminasi fitur	Disederhanakan
Derajat polinomial	Tidak disebutkan	2 (asumsi)	Tidak dirinci artikel
Split data	Rasio tidak dirinci	Acak 80/20, *seed* 42	Tidak dirinci artikel
Validasi silang	Jumlah *fold* tidak dirinci	3-*fold*, metrik R^2	Tidak dirinci artikel
Grid λ	Tidak dirinci; terpilih 0,001	$\{10^{-5}, \ldots, 10^{-2}\}$	Tidak dirinci artikel
Elastic Net	Menyetel λ dan α; α terpilih 0	$\alpha = 0{,}5$ tetap; hanya λ disetel	Disederhanakan; hasil tidak harus identik dengan Ridge
DTR	`maxDepth`=5	`maxDepth`=5	Sama

C. Hasil Pengujian dan Analisis

Catatan sumber data. Data yang dipakai adalah `daily_dataset` Block 0 (818 hari), bukan data setengah-jam seperti pada artikel. Kolom ketiga berkas dibaca sebagai `energy`; nilainya diduga median konsumsi per setengah jam dalam satu hari (kWh/hh) karena rentangnya sesuai, tetapi header berkas belum diperiksa eksplisit. Akibatnya fitur `hour` selalu 0, profil harian tidak dapat dianalisis, dan metrik galat absolut tidak sebanding langsung dengan artikel. Label sumbu pada gambar mengikuti keluaran notebook.

C.1 Analitik deskriptif dan seleksi fitur

Data final berisi 818 *timestamp*: `energy_sum` rata-rata 11,44 (simpangan baku 7,31; rentang 0,0635–28,89), `n_house` rata-rata 31,2 (rentang 1–50), `app_temp` rata-rata 7,89 °C (rentang $-8{,}52$ sampai 22,59 °C), dan 30,7% berstatus akhir pekan/libur.



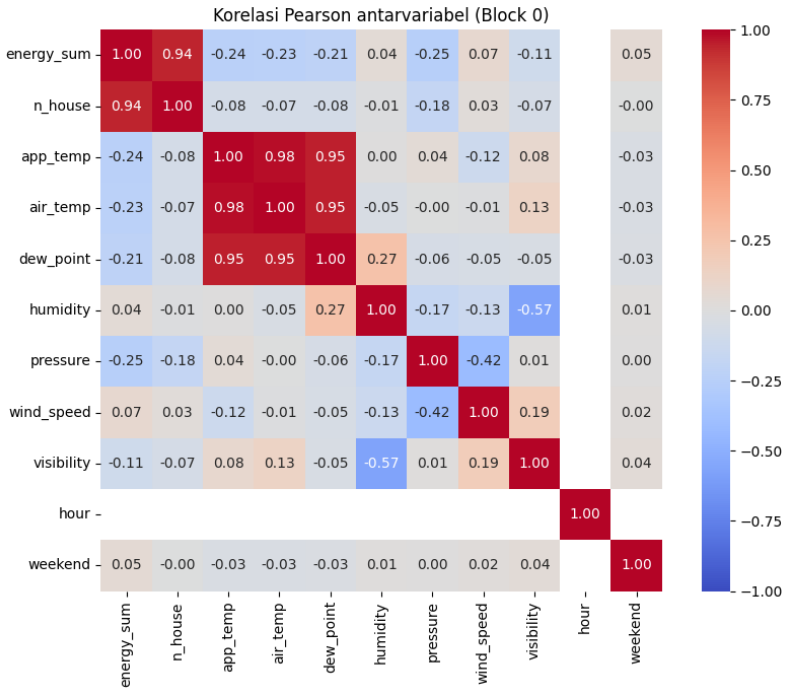
Gambar 1. Kiri: rata-rata beban bulanan (batang) dan *apparent temperature* (garis). Kanan: rata-rata beban per *bin* suhu 1 °C.

Beban rata-rata cenderung lebih rendah pada bulan hangat (Mei–Agustus) dan lebih tinggi pada bulan dingin, tetapi puncaknya jatuh pada November, bukan bulan terdingin. Penyebab yang paling mungkin adalah jumlah rumah tercatat yang berubah sepanjang periode sehingga skala `energy_sum` ikut bergeser; pola musiman tidak dapat dipisahkan dari efek ini tanpa normalisasi per rumah. Kurva beban terhadap suhu menurun dengan suhu yang meningkat dan tidak mulus, sehingga model polinomial wajar dicoba. Titik pada -7 dan -6 °C bernilai hampir nol karena hanya diwakili 1–2 hari awal periode ketika `n_house`=1 dan tidak perlu ditafsirkan.

Tiga fitur suhu (`air_temp`, `app_temp`, `dew_point`) saling berkorelasi sangat tinggi ($r = 0{,}95$–$0{,}98$), sehingga hanya satu yang dipertahankan. Tabel 1 memuat korelasi tiap fitur dengan target.

Fitur	r dengan `energy_sum`	**Fitur**	r **dengan** `energy_sum`
`n_house`	0,938	`dew_point`	−0,213
`pressure`	−0,252	`visibility`	−0,105
`app_temp`	−0,241	`wind_speed`	0,075
`air_temp`	−0,232	`weekend` / `humidity`	0,051 / 0,044
`hour`: tidak terdefinisi (nilai konstan)			

Di antara tiga suhu, `app_temp` memiliki $|r|$ tertinggi terhadap target, sama dengan pilihan artikel. Fitur akhir adalah `n_house`, `app_temp`, `hour`, dan `weekend`, dengan $|r|$ tertinggi antarfitur terpilih hanya 0,08. Temuan penting: `n_house` berkorelasi 0,938 dengan target, jauh melampaui fitur cuaca, sehingga `energy_sum` sebagian besar mencerminkan jumlah rumah tercatat, bukan perilaku konsumsi per rumah.



Gambar 2. Peta panas korelasi Pearson antarvariabel (Block 0).

Tabel 2 membandingkan korelasi dengan artikel (nilai absolut).

Pasangan	Artikel	Replikasi
`energy_sum` ∼ `air_temp`	0,43	0,232
`energy_sum` ∼ `app_temp`	0,45	0,241
`energy_sum` ∼ `dew_point`	0,44	0,213
`air_temp` ∼ `app_temp`	0,84–0,99	0,983
`air_temp` ∼ `dew_point`	0,84–0,99	0,951
`app_temp` ∼ `dew_point`	0,84–0,99	0,948

Korelasi antarfitur suhu berada dalam rentang artikel, sedangkan korelasi suhu dengan target jauh lebih rendah (≈0,21–0,24 dibanding 0,43–0,45), yang konsisten dengan perbedaan granularitas dan definisi target.

C.2 Kinerja model

Tabel 3 memuat hasil pada data uji (156 *timestamp*).

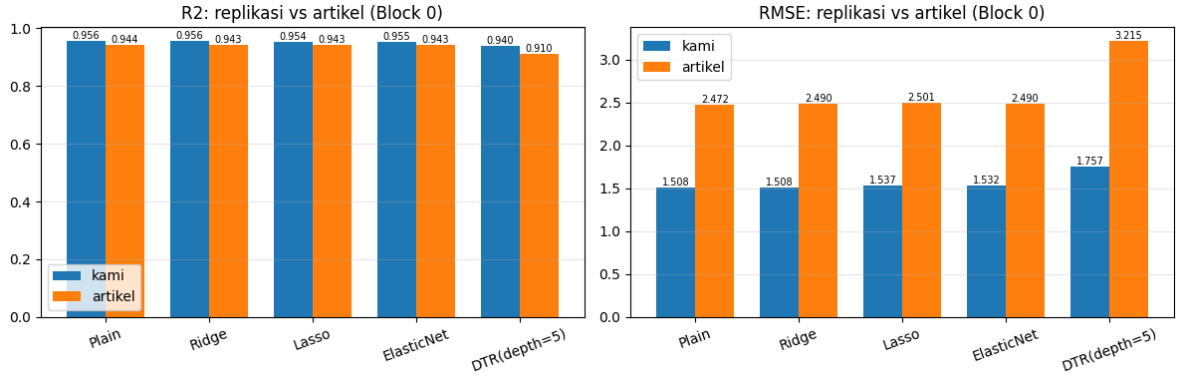
Model	R^2	MAE	MSE	RMSE	*fit* (s)	uji (s)	λ
Plain	0,9561	1,0615	2,2735	1,5078	2,44	0,57	–
Ridge	0,9561	1,0614	2,2734	1,5078	28,96	0,33	10^{-4}
Lasso	0,9544	1,0834	2,3612	1,5366	24,07	0,22	10^{-4}
Elastic Net	0,9547	1,0972	2,3465	1,5318	21,78	0,43	10^{-3}
DTR (depth=5)	0,9403	1,1464	3,0887	1,7575	2,46	0,33	–

Empat varian MPR mencapai R^2 0,954–0,956 dan DTR 0,940. Rentang R^2 antarvarian MPR hanya 0,0017, sehingga regularisasi nyaris tidak mengubah akurasi; Ridge praktis identik dengan Plain. MPR unggul atas DTR pada seluruh metrik. R^2 yang tinggi sebagian besar didorong oleh `n_house`, dan data uji hanya 156 baris dengan satu *split*, sehingga selisih kecil antarmodel tidak dapat dianggap bermakna.

C.3 Perbandingan dengan artikel

Tabel 4 membandingkan hasil replikasi (Rep.) dengan Tabel 6 artikel (Art.), kolom Block 0.

	R^2		MAE		MSE		RMSE	
Model	Rep.	Art.	Rep.	Art.	Rep.	Art.	Rep.	Art.
Plain	0,956	0,944	1,061	1,721	2,274	6,112	1,508	2,472
Ridge	0,956	0,943	1,061	1,769	2,273	6,202	1,508	2,490
Lasso	0,954	0,943	1,083	1,778	2,361	6,253	1,537	2,501
Elastic Net	0,955	0,943	1,097	1,769	2,346	6,202	1,532	2,490
DTR	0,940	0,910	1,146	2,004	3,089	10,338	1,757	3,215



Gambar 3. R^2 dan RMSE: replikasi ("kami") dan artikel, Block 0.

Kesamaan. Pola kualitatif utama sesuai artikel: semua varian MPR lebih akurat daripada DTR, regularisasi tidak mengubah akurasi secara berarti (rentang R^2 0,0017 pada replikasi dan 0,001 pada artikel), dan *Elastic Net* sangat dekat dengan Ridge (selisih R^2 0,0014). Selisih R^2 terhadap artikel kecil: 1,2–1,4% untuk MPR dan 3,3% untuk DTR.

Selisih. Galat absolut replikasi jauh lebih kecil: MAE lebih rendah 38–43%, MSE 62–70%, dan RMSE 38–45%. Angka ini **tidak** berarti model replikasi lebih baik. Penyebab utamanya adalah perbedaan skala dan granularitas target (data harian dari median per setengah jam, bukan data setengah-jam); galat absolut bergantung pada skala target, sehingga hanya R^2 yang dapat dibandingkan secara kasar. Dugaan ini belum diuji dengan menjalankan ulang pada `halfhourly_dataset`.

Klaim kualitatif artikel. Notebook memeriksa sembilan klaim; empat cocok dan lima tidak (Tabel 5).

Klaim artikel	Hasil replikasi	Cocok
R^2 semua varian MPR lebih tinggi daripada DTR	MPR min. 0,954; DTR 0,940	Ya
RMSE DTR lebih besar daripada semua varian MPR	DTR 1,757; MPR maks. 1,537	Ya
Regularisasi vs. Plain hampir sama (rentang $R^2 < 0{,}01$)	Rentang 0,0017	Ya
Elastic Net $\approx$ Ridge (selisih $R^2 < 0{,}01$)	Selisih 0,0014	Ya
Plain memiliki MAE terendah	Ridge 1,0614 vs. Plain 1,0615	Tidak

Klaim artikel	Hasil replikasi	Cocok
λ terpilih ketiga model regularisasi = 0,001	Ridge 10^{-4}, Lasso 10^{-4}, *Elastic Net* 10^{-3}	Tidak
Waktu uji model regularisasi lebih kecil daripada Plain dan DTR	Regularisasi maks. 0,43 s; Plain 0,57 s; DTR 0,33 s	Tidak
Waktu *fit* Ridge lebih kecil daripada Lasso dan *Elastic Net*	Ridge 29,0 s; Lasso 24,1 s; *Elastic Net* 21,8 s	Tidak
Waktu *fit Elastic Net* tertinggi di antara semua model	Tertinggi: Ridge (29,0 s)	Tidak

Klaim MAE ditolak hanya karena Ridge unggul tipis (selisih 0,0001), jauh di bawah derau pada 156 data uji; secara praktis Plain dan Ridge setara. Perbedaan λ wajar karena grid artikel tidak dirinci. Pada klaim waktu, waktu *fit* varian regularisasi jauh lebih lama daripada Plain dan DTR (21,8–29,0 s dibanding sekitar 2,4 s), sesuai sifat `CrossValidator` (4 nilai $\lambda \times 3$ *fold* + 1 *refit*), tetapi urutan antar Ridge, Lasso, dan *Elastic Net* berbeda dari artikel. Dugaannya, pada data sekecil ini (662 baris) waktu didominasi *overhead* Spark mode lokal dan pemanasan JVM, dan *Elastic Net* di sini tidak menyetel α. Pengukuran hanya satu kali sehingga belum dapat dipastikan.

Keterbatasan. (1) Granularitas data berbeda: 818 hari, `hour` konstan, efektif hanya tiga fitur yang bervariasi. (2) Definisi target berbeda sehingga galat absolut tidak sebanding. (3) `n_house` (1 sampai 50) berkorelasi 0,938 dengan target sehingga R^2 tinggi sebagian besar mencerminkan jumlah rumah. (4) *Timestamp* harian berjam 00:00, sehingga cuaca yang digabung hanya cuaca pukul 00:00, bukan rata-rata harian. (5) Data uji hanya 156 baris, satu *split*, dan waktu diukur sekali. (6) Derajat polinomial, rasio *split*, jumlah *fold*, dan grid λ adalah asumsi; *one-hot* dan eliminasi fitur tidak direplikasi; *Elastic Net* mengunci $\alpha = 0{,}5$.

D. Kendala dan Refleksi

- **Nilai `"Null"` dan mode ANSI Spark 4.** Membaca dengan `inferSchema` salah menebak tipe dan *cast* berpotensi galat. Diatasi dengan skema teks eksplisit, *cast* ke `double`, dan menonaktifkan `spark.sql.ansi.enabled`.
- **Zona waktu.** Pergeseran jam akibat DST dihindari dengan menetapkan zona waktu sesi ke UTC.
- **Parameter yang tidak dirinci artikel.** Derajat polinomial, rasio *split*, dan grid λ ditetapkan sebagai asumsi eksplisit dan dicatat pada B.5.
- **Berkas data harian, bukan setengah-jam.** Disadari setelah hasil ditinjau, dari fitur `hour` yang konstan dan jumlah *timestamp* yang hanya 818. Dampaknya dipaparkan terbuka pada Catatan sumber data dan Keterbatasan.

Jika diulang: memeriksa nama kolom dan granularitas berkas sebelum memodelkan; menjalankan ulang seluruh alur pada `halfhourly_dataset` Block 0 agar `hour` bermakna dan metrik sebanding dengan artikel; memperluas ke beberapa blok (parameter `BLOCKS`) agar Spark dimanfaatkan pada data lebih besar; menormalkan target per rumah; mengulang pengukuran waktu beberapa kali; dan menyetel α pada *Elastic Net*. Hasil yang tampak lebih baik daripada artikel perlu diselidiki penyebabnya lebih dulu sebelum disimpulkan.

E. Tautan Kode

Repositori: `https://github.com/WillJe65/123140208_mahadata`

Pernyataan Penggunaan Generative AI

Generative AI digunakan untuk membantu menulis kode notebook dan menyusun draf laporan ini. Penulis

bertanggung jawab atas kebenaran isi dan menjalankan serta memahami kode tersebut.

Daftar Pustaka

Ali, H. A. E.-S., Alham, M. H., & Ibrahim, D. K. (2024). Big data resolving using Apache Spark for load forecasting and demand response in smart grid: A case study of Low Carbon London Project. *Journal of Big Data, 11*, Article 59. https://doi.org/10.1186/s40537-024-00909-6

jeanmidev. (n.d.). *Smart meters in London* [Data set]. Kaggle. https://www.kaggle.com/datasets/jeanmidev/smart-meters-in-london

Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., & Stoica, I. (2016). Apache Spark: A unified engine for big data processing. *Communications of the ACM, 59*(11), 56–65. https://doi.org/10.1145/2934664